

基于快速Kolmogorov-Arnold网络的邻域聚集图转换器增强代谢-疾病关联预测

卢鹏丽*, 张健

摘要-代谢物是细胞化学反应的必需产物, 对维持生命和繁殖至关重要。它们在细胞生长、分化和免疫反应中起着核心作用。研究表明, 患者体内代谢物浓度不同于健康个体, 这使得基于代谢物的疾病预测对诊断和治疗至关重要。然而, 传统的生物学实验耗时且成本高昂, 目前的计算方法在准确性和可解释性方面仍然存在局限性。为了解决这些限制, 我们提出了一种新的邻域聚集图转换器方法(AGKphormer), 该方法结合了快速Kolmogorov-Arnold网络(FastKAN), 通过使用乘法器的交替方向方法(ADMM)优化最小核范数来增强链路关系。具体而言, 我们首先基于代谢物与疾病之间的相关性, 以及代谢物与疾病之间的相似性网络构建了一个异构网络。然后, 我们利用ADMM算法通过求解最小核范数来增强链路关系, 从而增加节点之间的稀疏关系, 为神经网络的学习提供更全面、更丰富的特征。随后, 对于由图卷积网络(GCN)学习和编码的邻域特征, 我们进一步利用FastKAN增强的图转换器来学习远程依赖关系。这种方法不仅实现了全局特征嵌入, 解决了GCN的平滑性问题, 而且由于FastKAN, 增强了可解释性。最后, 我们使用双线性解码器对复合嵌入进行解码和评分, 以获得最终的预测结果。通过5次交叉验证, AGKphormer的平均AUC和AUPR值分别为97.32%和97.34%, 优于现有方法, 证明了其预测疾病相关代谢物的有效性和准确性。我们还进行了消融实验, 以验证模型内每个模块的贡献及其整体稳健性。最后, 通过案例研究, 我们进一步证明了AGKphormer是发现潜在代谢物的可靠工具。

索引术语-疾病代谢物关联, 图卷积网络, 图转换器, 快速Kolmogorov-Arnold网络

I. 介绍

代谢物与疾病有着复杂而多维的关系, 对维持机体内环境[1]的稳定和健康起着至关重要的作用。代谢物是化学反应的产物

它们发生在细胞内, 参与细胞生长、分化、功能维持和免疫反应等关键过程。代谢调节的不平衡或紊乱与多种疾病有关, 包括糖尿病[2]、肥胖[3]、心血管[4]疾病和脂肪肝疾病。例如, 代谢异常被认为是糖尿病和肝脏疾病之间联系的根本原因。胰岛素抵抗[5]、糖尿病、肥胖和脂肪肝与肝纤维化、肝硬化和肝癌[6]、[7]密切相关。

在疾病研究中, 代谢组学有助于揭示代谢物水平与疾病风险之间的分子机制。研究发现, 调节代谢物水平的遗传变异可能会影响基因表达和疾病风险。代谢性疾病是由基因突变或环境破坏影响主要消化器官或具有重要代谢功能的器官(如肝脏和胰腺)而引起的病症。代谢途径的中断可导致多种代谢性疾病, 包括酸碱失衡、代谢性脑疾病[10]和脂质代谢紊乱[11]。重大代谢性疾病, 如糖尿病、肥胖症、代谢综合征、心血管疾病、先天性代谢错误等, 都与代谢途径紊乱有关。代谢的作用也是癌症研究中越来越重要的一个方面。癌细胞依赖于低效的发酵代谢途径, 这种现象被称为“Warburg效应”[12], 这是许多癌症的标志, 反映了促进癌细胞生长和生存的代谢适应。癌细胞需要它们的营养输入作为细胞的基本组成部分, 从分解代谢途径转向合成代谢途径, 以支持它们的高增殖率[13]。因此, 代谢物与疾病之间存在着密切的联系, 深入了解这些联系, 对于疾病的预防、诊断和治疗具有重要意义。

传统的生物学实验可以提出假设, 检验代谢物与疾病之间的关系, 但这些实验往往耗时耗力。随着代谢组学和数据挖掘技术的进步, 已经建立了多个专门研究代谢组学的数据库, 包括METLIN[14]、HMDB[15]、gutMGene[16]等。与此同时, 也有了计算识别代谢物与疾病之间关系的方法, 这可以避免短板

陆鹏丽、张健, 兰州理工大学计算机与通信学院, 甘肃兰州730050。
(e-mail: jianzhang0934@163.com; lupengli88@163.com)。

传统实验的缺点。机器学习的发展产生了主要利用优化和复杂网络算法的方法。2018年, Hu等人使用随机行走识别疾病相关代谢物[17]。后来, Lei等人开发了一种基于KATZ的计算方法来预测代谢物-疾病关联[18]。这也是KATZ算法在代谢组学领域的首次应用。2020年, Lei等人提出了一种基于改进的二部网络投影算法的线性邻域相似性来预测代谢物与疾病之间的关联[19]。此外, Zhao等人于2021年推出了一个Deep-DRM模型, 采用图卷积网络和主成分分析(PCA)来识别代谢物与疾病的关联。同年, Zhang等人提出了LGBMMDA[21], 该方法从各种测量中提取特征, 应用PCA进行降噪, 并利用LGBM分类器进行分析。2022年, Tie等人提出了基于DeepWalk和随机森林[22]的代谢物-疾病关联预测算法。同一时期, Sun等人提出了一种带有注意机制的图神经网络来预测代谢物与疾病之间的关联[23]。2023年, Gao等人提出了一种基于自编码器和非负矩阵分解[24]的代谢物-疾病关联预测方法。尽管目前的预测模型取得了成就, 但仍然存在一些局限性。

与一般的计算方法相比, 深度学习的发展大大提高了计算效率。然而, 现有深度学习模型的核心思想是通过邻接矩阵传播和聚合信息, 以学习图的复杂表示。显然, 目前的深度学习方法过于依赖代谢物-疾病关联网络, 构建的关联网络过于稀疏, 只有0.77%的关联是已知的。这可能会导致信息丢失、准确性下降、难以捕获复杂模式等问题, 使得节点信息的探索不够深入, 限制了模型的性能。随着对GCN体系结构[25]的深入研究, 其缺点日益明显。尽管传统的GCN模型在处理图结构数据方面表现良好, 但可能会遇到梯度消失和过度平滑等问题, 导致模型难以区分不同的节点, 限制了模型捕获远程依赖关系的能力, 从而影响性能。此外, 变压器[26]的研究和应用也在迅速发展, 近年来, 在与图相关的任务中, 它们已经实现了与最先进的GNN模型相当或更好的性能。与传统的GNN相比, 它们可以处理图中的远程依赖关系和复杂的拓扑结构。但由于计算复杂度高、泛化能力差、可解释性低等问题, 在实际应用中仍需要进行更多的优化和改进。这将推动我们的工作向前发展。

受上述问题的启发, 我们提出了AGKphormer, 该算法采用ADMM算法优化算法最小化核规范以增强关联关系

, 然后使用基于GCN的模型并将FastKAN集成到Transformer模型中, 进一步推断代谢物与疾病之间的相关性。首先, 我们基于已知关联信息构建了异构网络、代谢物的集成相似网络和疾病的集成相似网络。接下来, 我们使用ADMM[27]优化算法求解异构网络上的最小核norm, 增强代谢物与疾病之间的联系, 补充疾病与代谢物之间的稀疏关联, 从而提高准确性。然后, 我们使用构造好的图神经网络从输入的图结构数据中学习特征嵌入。我们发现GCN的消息传递机制有助于整合表示和图结构。Transformer的核心是多头自关注机制, 该机制允许模型直接在序列中的任意两个位置之间建立连接, 有效地捕获远程依赖关系。将两者结合起来将获取图的更多拓扑信息, 并且我们在Transformer中利用FastKAN来增强其准确性和可解释性。最后, 使用双线性解码器重建疾病与代谢物之间的关联矩阵。以下总结了本研究的三个主要贡献。

- 我们首次采用基于ADMM算法的方法来最小化核范数, 以增强稀疏的疾病代谢物关联, 从而为后续的神经网络学习提供额外的特征。
- 通过将GCN与图转换器相结合, 我们开发了一个用于全局特征学习的神经网络, 从而提高了模型的整体准确性。
- 我们通过引入更具可解释性的FastKAN改进了图转换器的优化, 从而提高了模型学习过程的整体准确性和可解释性。
- 我们提出了一种基于增强链接关系的新型图神经网络AGKphormer, 它继承了传统图神经网络和变压器的优点, 同时引入了新的FastKAN, 能够更全面、更深入地挖掘特征信息。

我们在5倍交叉验证(5-CV)实验中评估了AGKphormer的性能, 结果优于之前的5种计算方法。此外, 我们基于AGKphormer进行了案例研究, 预测的前10对代谢-疾病对可以在相关文献中得到验证。这些结果表明, AGKphormer是预测潜在代谢物疾病关联的有效可行模型。

II. 初步研究

在本节中, 主要介绍数据库、代谢物-疾病关联、相似性度量等概念, 这些概念将在后续工作中用到。

A. 数据集

HMDB (Human Metabolome Database, <https://hmdb.ca/>)[15]是一个应用广泛的生化数据库, 侧重于存储与人体代谢相关的信息。HMDB提供了关于人体内小分子(代谢物)的详细数据, 这对于研究人类健康和疾病的代谢途径至关重要。该数据库的当前版本为5.0。我们从HMDB中提取的数据集包括疾病id (DOID)和相关代谢物信息。在从原始数据中去除噪声后, 筛选出一组精心策划的657种疾病、2624种代谢物和7772种检测到并量化的关联。此外, 疾病和代谢物分别使用MeSH唯一ID(医学主题词)[28]和HMDB ID统一命名, 最终获得265种疾病、2315种代谢物和4763种关联。

B. 代谢物疾病关联

为了深入研究疾病与代谢物之间的相互作用, 我们构建了一个邻接矩阵 $A = (a_{ij})_{N_m \times N_d}$ 来量化它们之间的关系。在这个矩阵中, N_m 和 N_d 分别代表代谢物和疾病的数量。具体来说, 如果疾病 i 与代谢物 j 之间存在已知的科学关联, 则矩阵 a 中的元素 a_{ij} 标记为1, 反之, 如果两者之间没有直接联系, 则 a_{ij} 为0。

在我们的研究中, 共确定了265种不同疾病和2315种代谢物之间的613475种潜在关联。在这些关联中, 4763个已被科学验证为阳性样本。为了平衡阳性和阴性样本的数量, 从而减少样本不平衡对模型性能的影响, 我们从608,712个未经证实的关联中随机选择了4,763个作为负样本。最终, 我们获得了包含9526个样本的数据集, 这些样本将用于后续的模式训练和测试。通过这种邻接矩阵的表示, 我们可以更直观地了解代谢物与疾病之间的相关性, 为发现疾病的生物标志物和代谢物的潜在应用提供了强大的分析工具。

C. 相似度度量

1)疾病语义相似度:基于MeSH数据库中的疾病信息, 计算疾病语义相似度[29]。疾病之间的关系可以用有向无环图(DAG)表示, 基于疾病本体的拓扑结构和疾病之间的层次化学关系, 引入了信息内容贡献因子。DAG使用MeSH描述符中的树数表示为 $DAG(d) = (d, T(d), E(d))$, 其中 $T(d)$ 表示 d 本身和 d 的所有祖先节点, $E(d)$ 表示从祖先节点到疾病节点的有向边集。疾病 $DV(d)$ 的语义值可以定义为

$$DV(d) = \sum_{n \in T(d)} D_d(n) \quad (1)$$

而疾病 n 对疾病 d 的语义贡献值 $D_d(n)$ 定义如下:

$$D_d(t) = \begin{cases} 1, & n = d \\ \max \{ \Delta \cdot D_d(n') \mid n' \in \text{children of } d \}, & n \neq d \end{cases} \quad (2)$$

其中 Δ 为语义贡献衰减因子, 一般定义为0.5, 影响父节点 d 与其子节点 n' 之间的 $D_d(n)$ 。与疾病 d 与 n 之间的距离成反比。

一般来说, 两种疾病 d_i 和 d_j 的共同祖先数量越多, 表明它们之间的相似性越高。因此, 将疾病 d_i 和 d_j 的语义相似度定义如下:

$$DSS(d_i, d_j) = \frac{\sum_{t \in T(i) \cap T(j)} (D_i(t) + D_j(t))}{DV(i) + DV(j)} \quad (3)$$

2) 疾病和代谢物的高斯核相似度:

高斯核[30]基于高斯(正态)分布, 用于度量数据点之间的相似性或距离。利用来自疾病代谢物关联网络的已知拓扑信息, 采用核方法从特征向量构造核函数, 以提取相关特征。疾病与代谢物的高斯核相似网络[31]可计算如下:

$$DGS(d_i, d_j) = \exp \left(-\omega_d \|IP(d_i) - IP(d_j)\|^2 \right) \quad (4)$$

$$MGS(m_i, m_j) = \exp \left(-\omega_m \|IP(m_i) - IP(m_j)\|^2 \right) \quad (5)$$

其中 $IP(d_i)$ 和 $IP(d_j)$ 表示数据点 d_i 和 d_j 的特征映射, 在式(4)(5)中, ω_d 和 ω_m 是一个权重参数, 用于正则化相似性度量中距离的影响。在这里, 我们将其值设为1, ω_d 和 ω_m 的计算结果为式(6)(7):

$$\omega_d = \omega'_d / \left(\frac{1}{n_d} \sum_{i=1}^{n_d} IP(d_i)^2 \right) \quad (6)$$

$$\omega_m = \omega'_m / \left(\frac{1}{n_m} \sum_{i=1}^{n_m} IP(m_i)^2 \right) \quad (7)$$

3)代谢物分子指纹相似度:代谢物分子指纹相似度[24]是指在代谢组学研究的背景下, 通过比较不同代谢物分子的指纹来评估其结构相似性。分子指纹是一种代表分子结构的编码方法;两种代谢物的分子指纹越相似, 其相似度得分就越高。以标准SMILES格式提取的代谢物的化学结构, 被转换成一组二元分子指纹。此后, 利用谷本系数[32], [33]来量化各种代谢物之间的差异。具体公式如下:

$$MFS(m_i, m_j) = \frac{c}{a + b - c} \quad (8)$$

式中, a 和 b 分别表示1在代谢物 m_i 和 m_j 的分子指纹图谱中出现的次数, c 表示1在代谢物 m_i 和 m_j 中常见出现的次数。




图1. agphormer模式的总体流程图。

III. 方法

图1展示了agphormer的工作流程。本文提出的模型分为四个步骤。首先，将疾病的语义相似度与疾病的高斯核相似度相结合构建疾病相似度矩阵NSD，同时将代谢物的高斯核相似度与代谢物分子指纹图谱相似度相结合构建代谢物相似度矩阵MSN。接下来，我们基于最小化核范数的ADMM优化方法，增强已知的代谢物与疾病之间的关联。然后，我们利用相似矩阵DSN和MSN以及增强的关联矩阵构建了一个异构网络。随后，我们将该异构网络作为输入输入到图卷积网络(GCN)中，其中GCN编码器用于邻域特征学习。然后将这些学习到的特征输入到我们改进的Trans-former编码器中，该编码器由多头注意(Multi-Head Attention)和fastKAN组成，利用残差连接来提

高训练效率。这种编码器在图中节点之间的远程依赖关系建模方面更有效，并且可以从多个子空间中学习节点表示。最后，使用双线性解码器对获得的代谢物-疾病嵌入进行解码，以重建代谢物-疾病邻接矩阵并推断潜在的代谢物-疾病关系。

A. 构建疾病与代谢物相似性网络

为了解决一些疾病没有相应的MeSH分子描述导致语义相似度为零的问题，我们将对疾病的高斯核相似度进行积分，构建一个综合相似度矩阵DSN。这种方法通过提供一种不完全依赖语义描述的替代相似性度量来帮助缓解这种情况，因此

增强相似性评估的鲁棒性。

$$DSN(d_i, d_j) = \begin{cases} DGS(d_i, d_j), & DSS(d_i, d_j) = 0 \\ \frac{DGS(d_i, d_j) + DSS(d_i, d_j)}{2}, & \text{otherwise} \end{cases} \quad (9)$$

同样，对于代谢物，也存在代谢物没有相应分子指纹图谱的情况，导致分子指纹相似度为零。为了解决这个问题，我们结合代谢物的高斯核相似度来构建一个综合相似矩阵MSN。

$$MSN(m_i, m_j) = \begin{cases} MGS(m_i, m_j), & MFS(m_i, m_j) = 0 \\ \frac{MGS(m_i, m_j) + MFS(m_i, m_j)}{2}, & \text{otherwise} \end{cases} \quad (10)$$

我们知道，疾病-疾病和代谢物-代谢物之间没有关联，因此我们构建疾病和代谢物之间的综合相似度，以补充同类型节点之间的相关性，从而更好地挖掘图中的信息，并更好地预测潜在的联系。此外，这对于理解生物过程和疾病的发病机制也非常重要。

B. 增强关联链接

经过数据处理，我们最终的数据集包括2315种代谢物和265种疾病，总共有613475对关联，其中只有4764对是已知的关联。这说明关联网络相当稀疏，已知关联仅占0.77%。原始关联矩阵只包含元素0和1，表示是否存在关联，并且相对稀疏，使得未知关联的预测相对困难。此外，我们认识到功能相似的代谢生活可能与功能相似的疾病相关。因此，通过分析代谢物与疾病之间的功能相似性，我们提出了一种基于ADMM优化算法的方法，通过最小化核规范来发现它们之间的潜在联系，从而取代元素0，为后续预测提供一个完整的矩阵。并增强模型预测的准确性和鲁棒性。过程如图2所示。




图2. 矩阵补全方法概述。

1)构造目标矩阵:为了避免由于矩阵的稀疏性而导致的问题，例如预测精度下降，本文解决了核范数的最小化来完成矩阵。首先，基于之前构建的代谢物和疾病相似网络以及代谢物-疾病相互作用邻接矩阵，构建异质代谢物-疾病网络T作为我们的目标矩阵，表示如下：

$$T = \begin{bmatrix} MSN & A \\ A^T & DSN \end{bmatrix} \quad (11)$$

不难推断，目标矩阵T的维数为 $(n + m) \times (n + m)$ ，即大小为 2315×2315 。构建目标矩阵T的目的是随后使用从溶液中获得代谢物-疾病相互作用的预测分数来填充缺失值。

2)完成矩阵:由于目标矩阵是一个低秩矩阵，我们将目标转换为最小化目标矩阵[34]的秩，这也可以是最小化矩阵的核范数[35]的问题。在这个过程中，我们发现ADMM算法[27]不仅分解速度快，而且在矩阵“瘦身”方面也取得了很好的性能。因此，我们最终将问题转化为：

$$\min_x \|X\|_* \quad \text{s.t.} \quad P_\Omega(X) = P_\Omega(T) \quad (12)$$

其中 $\|X\|_*$ represents为X的核范数， Ω is为目标矩阵节点的一组坐标，对应已知的代谢物-疾病对。 P_Ω is为 Ω 上的正交投影算子。

$$(P_\Omega(X))_{ij} = \begin{cases} X_{ij}, & (i, j) \in \Omega \\ 0, & \text{else} \end{cases} \quad (13)$$

除此之外，为了进一步增强ADMM算法，我们在方程中加入了正则化项和矩阵值约束，以保证预测分数落在(0, 1)范围内。此外，我们在函数中引入了辅助矩阵W，进一步提高了模型的收敛性能。得到的关键目标方程如下：

$$\min_x \|X\|_* + \frac{\alpha}{2} \|P_\Omega(W) - P_\Omega(T)\|_F^2 \quad \text{s.t.} \quad X = W, \quad 0 < W_{ij} < 1 \quad (0 \leq i, j \leq n + m)$$

式中 α 为表征误差项的参数， $0 \leq X_{ij} \leq 1$ 表示X中的所有元素都在(0,1)范围内，W为辅助矩阵。在前述公式的基础上，增广拉格朗日函数为：

$$L(W, X, Y, \alpha, \beta) = \|X\|_* + \frac{\alpha}{2} \|P_\Omega(W) - P_\Omega(T)\|_F^2 + \text{Tr}(Y^T(X - W)) + \frac{\beta}{2} \|X - W\|_F^2 \quad (15)$$

式中，Y为拉格朗日乘子， $\beta > 0$ 表示罚参数。我们将W、X、Y初始化为 $P_\Omega(T)$ ，

然后进行迭代。在第 k 次迭代时, 根据ADMM, 我们可以计算出 $W_{k+1}, X_{k+1}, Y_{k+1}$ 。当迭代结束时, 最终的预测矩阵 W^* 可以按照之前的 T 形式进行划分, 其中 A^* represents 为已完成的代谢物-疾病关联矩阵, 此时, A^* 中的空值填充了潜在的关联分数。迭代的预测矩阵和终止条件表示如下:

$$\begin{aligned} W^* &= \begin{bmatrix} MSN^* & A^* \\ A^{*T} & DSN^* \end{bmatrix} \\ d1_{k+1} &= \frac{\|X_{k+1} - X_k\|_F}{\|X_k\|_F} \leq \text{tol}_1, \\ d2_{k+1} &= \frac{|d1_{k+1} - d1_k|}{\max\{|d1_k|, 1\}} \leq \text{tol}_2 \end{aligned} \quad (16)$$

C. Graph Encoder

本节将详细介绍我们设计的图形编码器。通过GCN实现邻域特征聚合, 并与我们结合FastKAN的Transformer协作, 全面挖掘图的特征信息, 增强模型的整体精度和可解释性, 实现对不同路径邻域信息的更高效编码。

1) 邻域特征聚合: GCN[25]是一种为处理图结构数据而设计的神经网络。GCN的核心思想是将每个节点的相邻节点的特征信息以及自身的特征信息进行聚合, 然后通过神经网络进行学习。首先, 对图的邻接矩阵 G 进行标准化, 得到 $\tilde{G}$, 这通常是通过将度矩阵 D 的逆与其平方根相乘来实现的, 即:

$$\tilde{G} = D^{-\frac{1}{2}} G D^{-\frac{1}{2}}. \quad (17)$$

接下来, 将标准化的邻接矩阵 $\tilde{G}$ 与节点特征矩阵 X 相乘, 实现特征信息的聚合。最后, 通过矩阵乘法将学习到的权重矩阵 W 与聚合的特征相乘, 得到下一层的节点特征表示。GCN的图卷积运算可以用下式表示:

$$H = D^{-\frac{1}{2}} \tilde{G} D^{-\frac{1}{2}} X W \quad (18)$$

其中 D 是输入图的度矩阵, X 是节点在 L 层的嵌入, W 是特定层的可训练权重矩阵。为了更好地利用相似性特征, 我们将输入邻接矩阵设置为:

$$G = \begin{bmatrix} MSN & A^* \\ A^{*T} & DSN \end{bmatrix} \quad (19)$$

G 由代谢物和疾病的集成相似矩阵 MSN 和 DSN , 以及前面描述的完整邻接矩阵 A^* 构建而成。然后我们初始化

特征矩阵为:

$$X = \begin{bmatrix} 0 & A \\ A^T & 0 \end{bmatrix} \quad (20)$$

最后, 根据公式, 我们从输入图中学习, 得到一个新的特征矩阵作为后续输入。

2) 多头注意: 在这里, 我们使用图转换器[37]实现了多头注意[36]机制, 作为能够学习和捕获远程依赖关系的消息传递神经网络层。具体来说, 对于图卷积后的节点特征 $H \in \mathbb{R}^{n \times d}$, 我们使用可学习的权重分别计算每个节点特征 h_i 对应的查询、键和值:

$$Q_i = W_q h_i, \quad K_i = W_k h_i, \quad V_i = W_v h_i, \quad (21)$$

然后将变换后的结果分成多个头像。对于每个头像, 我们计算查询 q_i 和所有关键字 k_j 的点积, 然后除以一个比例因子(通常是输出维度的平方根), 得到非标准化的注意力得分。然后, 使用softmax函数[38]对注意力分数进行归一化, 得到注意力权重:

$$\alpha_{i,j} = \text{softmax}\left(\frac{Q_i^T K_j}{\sqrt{d_k}}\right) \quad (22)$$

其中 d_k 为键向量的维数。

将归一化的注意力权重乘以它们对应的值 v_j , 对所有节点求和, 得到聚合特征:

$$x_i = \sum_{j \in N(i)} \alpha_{i,j} V_j \quad (23)$$

其中 $N(i)$ 表示节点 i 的相邻节点集合, 那么, 我们使用拼接将所有头的输出连接起来:

$$m_i = \text{Concat}(x_i^1, x_i^2, \dots, x_i^H) \quad (24)$$

此外, 我们使用残差连接[39]将原始节点特征与聚合特征结合起来, 解决了梯度消失的问题:

$$h'_i = W_o h_i + m_i \quad (25)$$

其中 W_o 为可学习权重矩阵。最后, 节点 i 的输出特征 h'_i 是聚合特征和跳跃连接的组合。综上所述, 基于以上公式, 对于GCN输出特征 H , 多头注意力捕获更深层次的嵌入信息, 最终输出特征为:

$$x'_i = W_o x_i + \sum_{j \in N(i)} \text{softmax}\left(\frac{(W_q x_i)^T (W_k x_j)}{\sqrt{d_k}}\right) W_v x_j \quad (26)$$

3) fastKAN: 为了增强非线性和增强模型的表达能力, 以及帮助模型理解数据中的全局和局部结构, 我们引入了fastKAN[40], 与传统的前馈神经网络相比, 它具有更高的精度和可解释性。

受Kolmogorov-Arnold表示定理的启发, 一种名为Kolmogorov-Arnold网络(KAN)[41]的新型神经网络架构诞生了。与传统的多层感知器(MLP)不同, KAN的核心思想是

将每个权重参数替换为可学习的单变量函数，通常是参数化样条函数，因此整个网络不包含线性权重。具体来说，KAN将函数 $f(x)$ 表示为：

$$f(\mathbf{x}) = \sum_q \Phi_q \left(\sum_p \phi_{q,p}(x_p) \right) \quad (27)$$

其中 Φ 和 $\Phi_{q,p}$ 为单变量函数。KAN的设计允许它将复杂的功能分解成更简单的组件，使网络更容易掌握。该网络使用 b 样条来构造一系列函数，这些函数可以有效地近似光滑的单变量函数。然而，在训练过程中，如果变量超过了集合的邻域，则需要对样条网格进行调整。这种调整过程需要通过deBoor-Cox迭代重新计算 b 样条[43]基，这可能导致KAN的效率瓶颈。

为了在保持精度的同时提高效率，我们采用FastKAN作为传统方法的替代品。FastKAN使用高斯核径向基函数(rbf)来近似三阶 b 样条基。此外，采用层归一化处理防止输入数据超出rbf的范围。

径向基函数(Radial Basis Function, RBF)[44]的基本思想是通过组合几个径向对称函数来建模一个函数，每个函数的中心位于输入空间的不同点。RBF网络的输出是这些径向基函数的线性组合，并由可调系数加权：

$$f(x) = \sum_{i=1}^N w_i \phi(\|x - c_i\|) \quad (28)$$

其中 w_i 为可学习权值，它取决于输入 x 与中心之间的距离 c_i 。高斯函数是一种常见的RBF：

$$\phi(\|x - c_i\|) = \exp\left(-\frac{\|x - c_i\|^2}{2h^2}\right) \quad (29)$$

其中 $\|x - c_i\|$ 为径向距离， h 是控制函数宽度或扩散的参数。

具体来说，对于我们之前学到的特征，我们应用层归一化，然后通过RBF生成高维特征，接下来，将RBF生成的高维特征平坦化，并使用样条线性层将它们映射到输出维度。最后，通过激活函数对原始输入特征进行处理并进行线性映射后，将其添加到RBF特征的输出中，得到生成层的输出。这将进一步帮助我们提取特征信息。

D. Decoder

通过我们的编码器对节点特征进行编码以捕获全局和远程结构信息后，我们获得了代谢物和疾病的最终嵌入。随后，我们利用双线性解码器将节点嵌入转换为代谢物与疾病之间

的关联概率，从而得到最终的关联矩阵：

$$H^{(2)} = \begin{bmatrix} H_m^{(2)} \\ H_d^{(2)} \end{bmatrix} \quad (30)$$

$$A' = \text{sigmoid}\left(H_m^{(2)} W (H_d^{(2)})^T\right) \quad (31)$$

其中 $H_m(2) \in \mathbb{R}^{2315 \times 512}$ 和 $H_d(2) \in \mathbb{R}^{265 \times 512}$ 是疾病和代谢物的最终嵌入， $W \in \mathbb{R}^{512 \times 512}$ 是可训练权值。

此外，在分类任务中，交叉熵损失函数[45]是一个非常受欢迎的选择，因为它可以量化预测概率分布与真实标签概率分布之间的差异。具体的实现包括：

$$L = -y \log(\hat{y}) - (1 - y) \log(1 - \hat{y}) \quad (32)$$

其中 $y = 0$ 或 1 表示真实标签， $y' \in [0, 1]$ 表示疾病与代谢物之间关联的预测概率值。

同时，使用Adam优化器[46]对最小值进行优化，更新参数，加速了模型的收敛。为了防止过拟合，在编码过程中还使用了dropout[47]，目的是在不同批次中训练不同的子网。

IV. result

A. 评价指标

在构建我们的AGKphormer模型之后，我们使用评估指标来衡量其性能。为了彻底评估模型的有效性并选择最优配置，我们使用了高效实用的五倍交叉验证[48]机器学习方法。这种方法通过评估模型在不同子集上的性能来充分利用数据集，帮助我们更准确地选择最佳模型或调整超参数。

具体来说，我们将所有样本均匀地分成5个大小相等的子集。在每一轮交叉验证中，我们使用四个子集作为训练集来训练模型，而剩下的子集作为测试集来评估其性能。这种方法保证了每个样本都有机会被用作测试数据，保证了模型评估的全面性和可靠性。它不仅提高了数据利用的效率，也帮助我们更精确地估计模型的泛化能力。随着模型中阈值的变化，可以计算出真阳性率(TPR)和假阳性率(FPR)：

$$TPR = \frac{TP}{TP + FN} \quad (33)$$

$$FPR = \frac{FP}{TN + FP} \quad (34)$$

其中TP、TN、FP、FN分别代表真阳性、真阴性、假阳性、假阴性。

为了直观地展示我们提出的模型的性能，我们绘制了接收者工作特征(ROC)曲线。在该图中， x 轴表示假




图3. AGKphormer模型参数对平均AUC和AUPR的影响。(a) GCN层数, (b)输出维数, (c) dropout, (d)学习率。

正确率, 而y轴表示真阳性率。ROC曲线下的面积, 称为AUC值, 衡量模型区分不同类别的能力。为了反映模型对真实样本的富集能力, 我们使用precision和recall之间的关系来获得AUPR值, 即precision - recall曲线下的面积。此外, 我们采用准确率(Acc)、精度(Pre)、召回率和F1分数作为评价指标:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (35)$$

$$Precision = \frac{TP}{TP + FP} \quad (36)$$

$$Recall = \frac{TP}{TP + FN} \quad (37)$$

$$F1 = \frac{1}{\frac{1}{Precision} + \frac{1}{Recall}} \quad (38)$$

B. 参数实验

在使用矩阵补全和神经网络对代谢生命和疾病之间的关联进行建模之后, 我们使用pytorch深度学习框架实现了AG

Kphormer。在训练过程中, 我们使用大量参数对模型进行微调, 为了加快模型收敛, 我们还使用了Adam优化器。在五重交叉验证中, 每一层训练200次, GCN层数、多头注意头数、辍学率和学习率等超参数都会影响模型的性能。

我们使用保持变量不变的方法来确定每个参数的最优值。我们从集合{1,2,3,4}中选择GCN层数, 从集合{32, 64,128,256}中选择编码器的输出维数, 从集合{0.009,0.007,0.005,0.003,0.001}中选择学习率, 从集合{0.1,0.2,0.3, 0.4,0.5}中选择dropout。图3显示了五重交叉验证下这些参数对AUC和AUPR的影响, 我们可以看到, 当存在两层GCN时, 算法在性能和复杂性方面表现最佳, 保持平衡, 输出维数为128, 学习速率为0.005,dropout率为0.2。

此外, 我们进行了实验, 并对模型的其他参数进行了过滤。在疾病语义相似度的计算中, 我们将 Δ 设为0.5, 核带宽 ω in 高斯核相似度设为1。对于矩阵




图4. (a)五重交叉验证下AGKphormer模型的ROC曲线。(b)五重交叉验证下AGKphormer模型的PR曲线。

完成后，我们将ADMM算法的惩罚参数 ρ 设为1，阈值参数 α 设为0.01。在五重交叉验证中，我们选择Adam作为优化器，选择二元交叉熵函数作为损失函数。关于我们模型参数的选择，见表1。

表一
agkphormer的参数

Structure	Parameters	value
ADMM	ρ	1.0
	α	0.01
Encode	tol	1e-4
	GCN layers	2
	Output dimension of Layer1	64
	Output dimension of Layer2	64
	The heads of MHA	1
	Output dimension of MHA	64
	dropout	0.2
	learning rate	0.005
	Loss function	binary cross entropy
	Optimizer	Adam
	Epoch	200
	init scale	0.1
	grid min	-2
	grid max	2
Decode	num grids	8
	base activation	silu
	gain	1.414

参数调优后，得到了最优结果，在TableII和Figure4中，我们对模型的综合性能进行了反馈。由表2可以看出，在最优参数下，AGKphormer模型的Acc、Pre、Recall和F1平均得分分别达到91.68%、90.91%、92.61%和91.75%。此外，如图4(a)所示，AGKphormer模型五重交叉验证的平均AUC达到97.43%，即97.37%、97.44%、97.50%、97.51%、97.31%的平均值。如图4(B)所示，AGKphormer模型五重交叉验证的平均AUPR为97.40%，即97.24%、97.30%、97.55%、97.58%、97.32%的平均值。这意味着，我们的

表二
agkphormer的参数

Fold	Acc(%)	Pre(%)	Recall(%)	F1(%)
1	91.02	91.85	90.02	90.93
2	92.33	91.55	93.28	92.40
3	91.07	90.39	91.91	91.15
4	91.96	90.56	93.70	92.10
5	91.20	89.39	93.51	91.40

模型精度好，泛化能力强，可解释性优越。AGKphormer模型的出色表现可归因于以下原因:首先，我们使用ADMM优化算法求解具有最小核范数的异构矩阵来完成关联矩阵，使原始关联矩阵不再稀疏，这更有利于我们更精确的预测。其次，我们将GCN与引入的FastKAN多头关注相结合，从异构网络中提取特征，在学习邻域特征的同时进一步学习全局特征;此外，FastKAN的引入提高了模型的可解释性，也证明了模型具有良好的泛化能力。通过对模型的训练和参数调优，达到了最佳的性能。

C. 烧蚀实验

为了进一步评估AGKphormer的性能和鲁棒性，我们对模型的模块进行了消融研究，以确定每个子模块的贡献。在保持其他模块不变的同时，我们一次删除一个模块，并在同一数据集上进行实验。

- Del-ADMM:我们不使用完整的关联矩阵;相反，我们利用原始的稀疏矩阵。
- Del-GCN:删除GCN层，只留下一个简化的编码器与多头关注和FastKAN。
- Del-MHA:一个简化的编码器，只保留GCN和FastKAN组件。





图5. AGKphormer和消融模型的平均AUPR和AUC进行五重交叉验证

Del-FastKAN:移除FastKAN以获得由GCN层和多头注意组成的编码器。

如图5所示,通过不同组分对AUC和AUPR的影响,展示了AGKphormer模型在烧蚀研究中的性能。通过逐步从模型中去除各种成分,我们可以评估每个部分对整体性能的贡献。结果表明,完整AGKphormer模型的AUC和AUPR值最高,分别达到97.32%和97.34%。当去除不同成分时,模型的性能下降。Del-ADMM的AUC和AUPR值分别下降到95.77%和95.13%,说明关联矩阵的补全可以提高模型的精度。Del-GCN进一步降低了AUC和AUPR值,分别为94.03%和94.06%,突出了GCN层在特征提取中的重要性。Del-MHA的AUC和AUPR分别为95.08%和93.65%,表明多头注意机制有利于获取远程依赖。Del-FastKAN的AUC和AUPR值分别为96.39%和95.84%,性能有所下降,说明FastKAN可以加速模型收敛,提高精度。

总体而言,烧蚀研究结果强调了AGKphormer模型中各组分的重要性,特别是GCN层和ADMM,它们对模型的最终性能有显著影响。通过这一分析,我们可以更好地了解模型的内部工作机制,并为未来的模型优化提供指导。

D. 与基准方法的比较

为了直观地展示AGKphormer的优势,我们将其与近年来生物信息学领域出现的关联预测方法进行了比较,并在相同的数据集上进行了测试和对比分析。

- 双随机行走(MDBIRW)[49]通过重建疾病相似网络预测疾病相关代谢物

以及代谢物功能相似网络,然后在这些网络上执行双随机行走算法。

- DWRF[22]集成了疾病和代谢物的多个相似性指标,应用DeepWalk进行特征提取,然后使用随机森林预测代谢物与疾病之间的关联。
- deep - drm[20]构建代谢物与疾病网络,使用GCN编码特征,应用PCA降维,通过深度神经网络识别相关代谢物。
- GCNAT[23]构建异构网络,用GCN对特征进行编码,使用图关注层集成嵌入,并进行解码和评分,预测疾病相关代谢物。
- MDA-AENMF[24]集成了各种相似网络,并使用自编码器和非负矩阵分解来提取特征,并将其合并为每个代谢物-疾病对的综合特征向量,以预测潜在的关联。

经过五次交叉验证,将AGKphormer算法与上述算法进行比较。图6显示了四种基线方法的评价指标对比。AGKphormer在所有关键指标上都具有显著优势。具体而言,AGKphormer的准确率(Acc)为91.52%,比第二优模型MDA-AENMF高出0.85%。它的准确率(Pre)也达到了90.75%,召回率(recall)高达92.48%,F1分数达到了91.60%。此外,如图7所示,AGKphormer的ROC和PR曲线明显优于其他五种基线方法。AGKphormer的ROC曲线下面积最大,AUC值为97.32%,分别比MDBIRW、DWRF、DeepDRM、GCNAT和MDA-AENMF高7.76%、2.21%、2.09%、2.11%和0.77%,表明我们的模型表现较为理想。此外,AGKphormer的PR曲线下面积最大,为97.34%,为7.32%;




图6。基于五重交叉验证的AGKphormer模型与五种基准方法的性能比较。




图7。(a)五重交叉验证下AGKphormer模型与基准方法的ROC曲线。(b)五重交叉验证下AGKphormer模型与基准方法的PR曲线。

比 MDBIRW、DWRF、DeepDRM、GCNAT 和 MDA-AENMF分别高2.19%、2.45%、2.20%和1.07%。这表明AGKphormer可以在保持较高的准确性的同时更好地识别所有阳性样品，突出了其卓越的性能和潜在的实际应用价值。

上述方法均利用稀疏二部异构网络。我们提出的方法是基于代谢物和疾病的相似性网络来完成代谢物-疾病关联矩阵。然后将该矩阵与相似度网络一起输入到GCN中进行特征提取。使用多头注意机制来捕获远程依赖关系，然后通过Fas

tKAN前馈网络进行进一步的非线性变换，最后对关联进行解码以获得最终的关系。这种方法不仅提高了准确性，而且增强了模型的可解释性。

E. 案例研究

为了进一步评估AGKphormer模型的性能和实际效果，我们对阿尔茨海默病和克罗恩病这两种复杂疾病进行了深入分析。具体来说，我们选择阿尔茨海默病和克罗恩病及其所有相关代谢物作为阳性样本作为测试集，并随机抽取相同数量的未知关联作为阴性样本。

然后我们使用这些疾病之外的所有样本作为训练集。最终，我们获得了特定疾病与代谢物之间的关联得分，对它们进行排名，并确定了排名前15位的相关代谢物。为了验证这些预测的准确性，我们使用HMDB和NCBI数据库进行了详细的文献检索和数据分析。

表iii

与阿尔茨海默病相关的前15种代谢物预测结果

Rank	Metabolite	Probability	PMID
1	Creatinine	0.9998	23857558
2	alpha-D-Glucose	0.9998	9693263
3	D-Glucose	0.9992	9693263
4	Hypoxanthine	0.9989	23857558
5	Homocysteine	0.9983	21474939
6	Adenine	0.9959	23857558
7	Chloroform	0.9951	None
8	L-Alanine	0.9921	23857558
9	Hexadecanedioic acid	0.9906	None
10	Dopamine	0.9902	17031479
11	Substance P	0.9899	11314776
12	Mannitol	0.9871	8595727
13	L-Arginine	0.9866	17031479
14	L-Proline	0.9855	17031479
15	Choline	0.9850	15465626

表四

与克罗恩病相关的前15种代谢物预测结果

Rank	Metabolite	Probability	PMID
1	L-Serine	0.9629	27609529
2	Glycine	0.9566	25598765
3	Isobutyric acid	0.9506	24811995
4	L-Glutamine	0.9422	27609529
5	D-Aspartic acid	0.9405	17269711
6	D-Glutamic acid	0.9382	17269711
7	L-Alanine	0.9358	17269711
8	L-Tyrosine	0.9340	25598765
9	Hydrocinnamic acid	0.9337	28842642
10	Acetic acid	0.9318	17269711
11	beta-Alanine	0.9293	28842642
12	Creatine	0.9276	27609529
13	L-Lysine	0.9228	17269711
14	L-Threonine	0.9210	17269711
15	Deoxyuridine	0.9186	27609529

阿尔茨海默病是一种常见的神经退行性疾病，主要影响老年人，导致记忆力、思维能力和行为能力逐渐下降。这是痴呆症最常见的一种形式，目前还没有治愈方法。治疗主要侧重于缓解症状和提高生活质量。阿尔茨海默病的确切病因尚不清楚，但它涉及多种遗传和环境因素。目前，一些学者发现阿尔茨海默病患者的代谢物浓度与健康人不同[10]。他们正试图根据代谢产物[52]来研究和提前诊断阿尔茨海默病。随着深度学习的发展，近年来出现了一些基于神经网络的方法。表iii列出了我们提出的AGKphormer模型预测的与阿尔茨海默病高度相关的前15种代谢物，其中13种已得到验证。我们的模型预测，肌酸[53]、 α -d-葡萄糖和d-葡萄糖[54]是与疾病相关度最高的

三种代谢物，概率值分别为0.9998、0.9998和0.9992。此外，其他代谢物的验证可以在参考文献中找到，如l-丙氨酸、次黄嘌呤和l-苯丙氨酸。这些高概率值表明这些代谢物与阿尔茨海默病之间有很强的联系。此外，我们的模型还预测了其他几种代谢物，如氯仿和十六烷二酸，它们也显示出与阿尔茨海默病的显著相关性。

克罗恩氏病是一种慢性炎症性肠病，可影响消化道的任何部位，但最常影响回肠末端和结肠。这种疾病通常会引起肠道的慢性炎症和溃疡，导致一系列不适和症状。对于克罗恩病，AGKphormer模型也表现异常出色，预测l-丝氨酸[56]、甘氨酸[57]和异丁酸[58]是与克罗恩病最密切相关的三种代谢物，概率值分别为0.9629、0.9565和0.9506。此外，其他代谢物的验证也可以在参考文献中找到。这些高概率值进一步证实了这些代谢物与克罗恩病之间的潜在联系。该模型还预测了与克罗恩病相关的其他代谢物，如l-谷氨酰胺、d-天冬氨酸和d-葡萄糖醛酸。排名前15位的预测代谢物都得到了验证。

V. 结论

代谢性疾病关联研究旨在探索代谢物与疾病之间的联系，以确定生物标志物和治疗靶点，这对疾病的诊断、治疗和预防至关重要。通过分析代谢物的变化，科学家可以揭示疾病机制，并为开发新的治疗方法提供基础。传统的生物实验耗时耗力。尽管近年来出现了计算方法，但其准确性和可解释性需要改进，需要新的算法来解决当前方法的缺点。我们提出的AGKphormer使用完整的关联矩阵和深度学习来学习特征，从而实现更准确的预测。首先，我们利用基于代谢物和疾病相似性网络的ADMM优化算法来完成已知的代谢物-疾病关联矩阵，使原始矩阵不那么稀疏。然后，我们采用GCN和多头关注进行特征学习，更有效地捕获远程依赖关系。最后，通过对最终嵌入进行评分，我们得到了预测结果。通过五重交叉验证，与基线方法相比，AGKphormer的AUC(97.32%)和AUPR(97.34%)均达到最佳效果。此外，我们对模型的模块进行了消融实验，验证了每个模块的贡献和整体鲁棒性。最后，我们对阿尔茨海默病和克罗恩病进行了案例研究，结果一致表明我们的模型在预测疾病和代谢物关联方面是精确的。

AGKphormer模型的性能提升主要是由于以下因素。首先，我们使用

ADMM算法通过求解最小核范数来完成原始稀疏矩阵,提高了原始数据的稀疏性,增强了模型的预测精度。其次,深度学习的快速发展极大地帮助我们提高了模型的性能;我们使用GCN提取节点的邻域特征,并学习数据的底层模式。第三,在学习邻域特征的同时,利用多头注意力捕获远程依赖关系,弥补了GCN算法的不足。此外,我们是第一个在疾病预测中使用FastKAN的,与传统神经网络相比,它提高了模型的可解释性。

数据可用性声明

代码和数据集可在[https:// github.com/](https://github.com/)在线获取。

资助

甘肃省产业支撑计划(No.24YFFA023)、甘肃省重点研发计划(No.2023CYZC-25)和甘肃省自然科学基金(No.23JRRA770)资助。

伦理声明

本研究遵循研究的伦理标准和准则进行,不涉及人类或动物受试者。所有作者已审阅并批准此稿件发表。

参考文献

- [1] D. Guerrero, L. Letrouit, and C. Pais-Montes, "The container transport system during covid-19: An analysis through the prism of complex networks," *Transport Policy*, vol. 115, pp. 113–125, 2022.
- [2] M. Dhanya and S. Hegde, "Salivary glucose as a diagnostic tool in type ii diabetes mellitus: A case-control study," *Nigerian journal of clinical practice*, vol. 19, no. 4, pp. 486–490, 2016.
- [3] D. J. Drucker, "Diabetes, obesity, metabolism, and sars-cov-2 infection: the end of the beginning," *Cell metabolism*, vol. 33, no. 3, pp. 479–498, 2021.
- [4] P. Amiri, S. A. Hosseini, S. Ghaffari, H. Tutunchi, S. Ghaffari, E. Mosharkesh, S. Asghari, and N. Roshanravan, "Role of butyrate, a gut microbiota derived metabolite, in cardiovascular diseases: A comprehensive narrative review," *Frontiers in Pharmacology*, vol. 12, p. 837509, 2022.
- [5] S.-H. Lee, S.-Y. Park, and C. S. Choi, "Insulin resistance: from mechanisms to therapeutic strategies," *Diabetes & metabolism journal*, vol. 46, no. 1, pp. 15–37, 2022.
- [6] M. Liu, T.-C. Tseng, D. W. Jun, M.-L. Yeh, H. Trinh, G. L. Wong, C.-H. Chen, C.-Y. Peng, S. E. Kim, H. Oh *et al.*, "Transition rates to cirrhosis and liver cancer by age, gender, disease and treatment status in asian chronic hepatitis b patients," *Hepatology international*, vol. 15, pp. 71–81, 2021.
- [7] D. Dhar, J. Baglieri, T. Kisseleva, and D. A. Brenner, "Mechanisms of liver fibrosis and its role in liver cancer," *Experimental Biology and Medicine*, vol. 245, no. 2, pp. 96–108, 2020.
- [8] Y. Chen, E.-M. Li, and L.-Y. Xu, "Guide to metabolomics analysis: a bioinformatics workflow," *Metabolites*, vol. 12, no. 4, p. 357, 2022.
- [9] D. J. Hoffman, T. L. Powell, E. S. Barrett, and D. B. Hardy, "Developmental origins of metabolic diseases," *Physiological reviews*, vol. 101, no. 3, pp. 739–795, 2021.
- [10] N. J. Jensen, H. Z. Wodschow, M. Nilsson, and J. Rungby, "Effects of ketone bodies on brain metabolism and function in neurodegenerative diseases," *International journal of molecular sciences*, vol. 21, no. 22, p. 8767, 2020.
- [11] J. Aron-Wisniewsky, M. V. Warmbrunn, M. Nieuwdorp, and K. Clément, "Metabolism and metabolic disorders and the microbiome: the intestinal microbiota associated with obesity, lipid metabolism, and metabolic health—pathophysiology and therapeutic strategies," *Gastroenterology*, vol. 160, no. 2, pp. 573–599, 2021.
- [12] P. Vaupel and G. Multhoff, "Revisiting the warburg effect: historical dogma versus current understanding," *The Journal of physiology*, vol. 599, no. 6, pp. 1745–1757, 2021.
- [13] I. Martínez-Reyes and N. S. Chandel, "Cancer metabolism: looking forward," *Nature Reviews Cancer*, vol. 21, no. 10, pp. 669–680, 2021.
- [14] J. R. Montenegro-Burke, C. Guigas, and G. Siuzdak, "Metlin: a tandem mass spectral library of standards," *Computational methods and data analysis for metabolomics*, pp. 149–163, 2020.
- [15] D. S. Wishart, A. Guo, E. Oler, F. Wang, A. Anjum, H. Peters, R. Dizon, Z. Sayeeda, S. Tian, B. L. Lee *et al.*, "Hmdb 5.0: the human metabolome database for 2022," *Nucleic acids research*, vol. 50, no. D1, pp. D622–D631, 2022.
- [16] L. Cheng, C. Qi, H. Yang, M. Lu, Y. Cai, T. Fu, J. Ren, Q. Jin, and X. Zhang, "gutmgene: a comprehensive database for target genes of gut microbes and microbial metabolites," *Nucleic acids research*, vol. 50, no. D1, pp. D795–D800, 2022.
- [17] Y. Hu, T. Zhao, N. Zhang, T. Zang, J. Zhang, and L. Cheng, "Identifying diseases-related metabolites using random walk," *BMC bioinformatics*, vol. 19, pp. 37–46, 2018.
- [18] X. Lei and C. Zhang, "Predicting metabolite-disease associations based on katz model," *BioData Mining*, vol. 12, pp. 1–14, 2019.
- [19] —, "Predicting metabolite-disease associations based on linear neighborhood similarity with improved bipartite network projection algorithm," *Complexity*, vol. 2020, no. 1, p. 9342640, 2020.
- [20] T. Zhao, Y. Hu, and L. Cheng, "Deep-drm: a computational method for identifying disease-related metabolites based on graph deep learning approaches," *Briefings in Bioinformatics*, vol. 22, no. 4, p. bbaa212, 2021.
- [21] C. Zhang, X. Lei, and L. Liu, "Predicting metabolite-disease associations based on lightgbm model," *Frontiers in Genetics*, vol. 12, p. 660275, 2021.
- [22] J. Tie, X. Lei, and Y. Pan, "Metabolite-disease association prediction algorithm combining deepwalk and random forest," *Tsinghua Science and Technology*, vol. 27, no. 1, pp. 58–67, 2021.
- [23] F. Sun, J. Sun, and Q. Zhao, "A deep learning method for predicting metabolite-disease associations via graph neural network," *Briefings in bioinformatics*, vol. 23, no. 4, p. bbac266, 2022.
- [24] H. Gao, J. Sun, Y. Wang, Y. Lu, L. Liu, Q. Zhao, and J. Shuai, "Predicting metabolite-disease associations based on auto-encoder and non-negative matrix factorization," *Briefings in bioinformatics*, vol. 24, no. 5, p. bbad259, 2023.
- [25] T. N. Kipf and M. Welling, "Semi-supervised classification with graph convolutional networks," 2017. [Online]. Available: <https://arxiv.org/abs/1609.02907>
- [26] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," 2023. [Online]. Available: <https://arxiv.org/abs/1706.03762>
- [27] S. Boyd, N. Parikh, E. Chu, B. Peleato, and J. Eckstein, "Distributed optimization and statistical learning via the alternating direction method of multipliers," *Foundations and Trends® in Machine Learning*, vol. 3, no. 1, pp. 1–122, 2011. [Online]. Available: <http://dx.doi.org/10.1561/22000000016>
- [28] C. E. Lipscomb, "Medical subject headings (mesh)," *Bulletin of the Medical Library Association*, vol. 88, no. 3, p. 265, 2000.
- [29] D. Wang, J. Wang, M. Lu, F. Song, and Q. Cui, "Inferring the human microRNA functional similarity and functional network based on microRNA-associated diseases," *Bioinformatics*, vol. 26, no. 13, pp. 1644–1650, 2010.
- [30] B. M. ter Haar Romeny, "The gaussian kernel," *Front-End Vision and Multi-Scale Image Analysis: Multi-Scale Computer Vision Theory and Applications, written in Mathematics*, pp. 37–51, 2003.
- [31] T. Van Laarhoven, S. B. Nabuurs, and E. Marchiori, "Gaussian interaction profile kernels for predicting drug-target interaction," *Bioinformatics*, vol. 27, no. 21, pp. 3036–3043, 2011.
- [32] H. Lim, A. Poleksic, Y. Yao, H. Tong, D. He, L. Zhuang, P. Meng, and L. Xie, "Large-scale off-target identification using fast and accurate dual regularized one-class collaborative filtering and its application to drug repurposing," *PLoS computational biology*, vol. 12, no. 10, p. e1005135, 2016.
- [33] P. Willett, J. M. Barnard, and G. M. Downs, "Chemical similarity searching," *Journal of chemical information and computer sciences*, vol. 38, no. 6, pp. 983–996, 1998.

- [34] A. Ramlatchan, M. Yang, Q. Liu, M. Li, J. Wang, and Y. Li, "A survey of matrix completion methods for recommendation systems," *Big Data Mining and Analytics*, vol. 1, no. 4, pp. 308–323, 2018.
- [35] E. Candes and B. Recht, "Simple bounds for recovering low-complexity models," *Mathematical Programming*, vol. 141, no. 1, pp. 577–589, 2013.
- [36] J.-B. Cordonnier, A. Loukas, and M. Jaggi, "Multi-head attention: Collaborate instead of concatenate," *arXiv preprint arXiv:2006.16362*, 2020.
- [37] Y. Shi, Z. Huang, S. Feng, H. Zhong, W. Wang, and Y. Sun, "Masked label prediction: Unified message passing model for semi-supervised classification," 2021. [Online]. Available: <https://arxiv.org/abs/2009.03509>
- [38] W. Liu, Y. Wen, Z. Yu, and M. Yang, "Large-margin softmax loss for convolutional neural networks," 2017. [Online]. Available: <https://arxiv.org/abs/1612.02295>
- [39] C. Szegedy, S. Ioffe, V. Vanhoucke, and A. Alemi, "Inception-v4, inception-resnet and the impact of residual connections on learning," in *Proceedings of the AAAI conference on artificial intelligence*, vol. 31, no. 1, 2017.
- [40] Z. Li, "Kolmogorov-arnold networks are radial basis function networks," 2024. [Online]. Available: <https://arxiv.org/abs/2405.06721>
- [41] Z. Liu, Y. Wang, S. Vaidya, F. Ruehle, J. Halverson, M. Soljačić, T. Y. Hou, and M. Tegmark, "Kan: Kolmogorov-arnold networks," 2024. [Online]. Available: <https://arxiv.org/abs/2404.19756>
- [42] H. Taud and J.-F. Mas, "Multilayer perceptron (mlp)," *Geomatic approaches for modeling land change scenarios*, pp. 451–455, 2018.
- [43] C. De Boor, "On calculating with b-splines," *Journal of Approximation theory*, vol. 6, no. 1, pp. 50–62, 1972.
- [44] M. D. Buhmann, "Radial basis functions," *Acta numerica*, vol. 9, pp. 1–38, 2000.
- [45] A. Mao, M. Mohri, and Y. Zhong, "Cross-entropy loss functions: Theoretical analysis and applications," in *International conference on Machine learning*. PMLR, 2023, pp. 23 803–23 828.
- [46] D. P. Kingma, "Adam: A method for stochastic optimization," *arXiv preprint arXiv:1412.6980*, 2014.
- [47] P. Baldi and P. J. Sadowski, "Understanding dropout," *Advances in neural information processing systems*, vol. 26, 2013.
- [48] T.-T. Wong and N.-Y. Yang, "Dependency analysis of accuracy estimates in k-fold cross validation," *IEEE Transactions on Knowledge and Data Engineering*, vol. 29, no. 11, pp. 2417–2427, 2017.
- [49] X. Lei and J. Tie, "Prediction of disease-related metabolites using bi-random walks," *PloS one*, vol. 14, no. 11, p. e0225380, 2019.
- [50] K. Blennow, M. J. de Leon, and H. Zetterberg, "Alzheimer' s disease," *The Lancet*, vol. 368, no. 9533, pp. 387–403, 2006.
- [51] Z. Chen and C. Zhong, "Decoding alzheimer' s disease from perturbed cerebral glucose metabolism: implications for diagnostic and therapeutic strategies," *Progress in neurobiology*, vol. 108, pp. 21–43, 2013.
- [52] J. M. Wilkins and E. Trushina, "Application of metabolomics in alzheimer' s disease," *Frontiers in neurology*, vol. 8, p. 719, 2018.
- [53] M. Tsuruoka, J. Hara, A. Hirayama, M. Sugimoto, T. Soga, W. R. Shinkle, and M. Tomita, "Capillary electrophoresis-mass spectrometry-based metabolome analysis of serum and saliva from neurodegenerative dementia patients," *Electrophoresis*, vol. 34, no. 19, pp. 2865–2872, 2013.
- [54] N. Redjems-Bennani, C. Jeandel, E. Lefebvre, H. Blain, M. Vidailhet, and J.-L. Guent, "Abnormal substrate levels that depend upon mitochondrial function in cerebrospinal fluid from alzheimer patients," *Gerontology*, vol. 44, no. 5, pp. 300–304, 1998.
- [55] F. Shanahan, "Crohn' s disease," *The Lancet*, vol. 359, no. 9300, pp. 62–69, 2002.
- [56] K.-L. Kolho, A. Pessia, T. Jaakkola, W. M. de Vos, and V. Velagapudi, "Faecal and serum metabolomics in paediatric inflammatory bowel disease," *Journal of Crohn's and Colitis*, vol. 11, no. 3, pp. 321–334, 2017.
- [57] J. T. Bjerrum, Y. Wang, F. Hao, M. Coskun, C. Ludwig, U. Günther, and O. H. Nielsen, "Metabonomics of human fecal extracts characterize ulcerative colitis, crohn' s disease and healthy individuals," *Metabolomics*, vol. 11, pp. 122–133, 2015.
- [58] V. De Preter, K. Machiels, M. Joossens, I. Arijis, C. Matthys, S. Vermeire, P. Rutgeerts, and K. Verbeke, "Faecal metabolite profiling identifies medium-chain fatty acids as discriminating compounds in ibd," *Gut*, vol. 64, no. 3, pp. 447–458, 2015.